

作业二 李云浩 241880324

题目一

(a)

对于未处理的数据，考虑 $Ent(D) = -\sum_{i=1}^{|y|} p_i \log_2 p_i$

第一个分支结点：

因此：

初始状态下的信息熵为： $Ent(D_0) = -(\frac{2}{8}\log_2 \frac{2}{8} + \frac{6}{8}\log_2 \frac{6}{8}) = 0.8113$

$D_1(X = 1) \Rightarrow Ent(D_1) = -(\frac{1}{4}\log_2 \frac{1}{4} + \frac{3}{4}\log_2 \frac{3}{4}) = 0.8113$

$D_2(X = 0) \Rightarrow Ent(D_2) = -(\frac{1}{4}\log_2 \frac{1}{4} + \frac{3}{4}\log_2 \frac{3}{4}) = 0.8113$

因此 $Gain(D_0, X) = Ent(D_0) - \sum_{v=1}^2 \frac{|D^v|}{|D|} Ent(D^v) = 0.8113 - (\frac{1}{2} \times 0.8113 + \frac{1}{2} \times 0.8113) = 0$

$D_3(Y = 1) \Rightarrow Ent(D_3) = -(\frac{1}{4}\log_2 \frac{1}{4} + \frac{3}{4}\log_2 \frac{3}{4}) = 0.8113$

$D_4(Y = 0) \Rightarrow Ent(D_4) = -(\frac{1}{4}\log_2 \frac{1}{4} + \frac{3}{4}\log_2 \frac{3}{4}) = 0.8113$

因此 $Gain(D_0, Y) = Ent(D_0) - \sum_{v=1}^2 \frac{|D^v|}{|D|} Ent(D^v) = 0.8113 - (\frac{1}{2} \times 0.8113 + \frac{1}{2} \times 0.8113) = 0$

$D_5(Z = 1) \Rightarrow Ent(D_5) = -(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{2}\log_2 \frac{1}{2}) = 1$

$D_6(Z = 0) \Rightarrow Ent(D_6) = -(1 \cdot \log_2 1) = 0$

因此 $Gain(D_0, Z) = Ent(D_0) - \sum_{v=1}^2 \frac{|D^v|}{|D|} Ent(D^v) = 0.8113 - (\frac{1}{2} \times 1 + \frac{1}{2} \times 0) = 0.3113$

由于 $Gain(D_0, Z) > Gain(D_0, X) = Gain(D_0, Y)$ ，因此第一个分支结点选择 Z 。

第二个分支结点

其中当 $Z = 0$ 的时候， $f(X, Y, Z) = 0$ ，无需再度划分。

考虑 $Z = 1$ 的后续结点，需要考虑的数据集为：

编号	X	Y	Z	f
1	1	0	1	1
2	0	1	1	1
3	0	0	1	0
4	1	1	1	0

该数据集的信息熵为： $Ent(D'_0) = -(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{2}\log_2 \frac{1}{2}) = 1$

$D'_1(X = 1) \Rightarrow Ent(D'_1) = -(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{2}\log_2 \frac{1}{2}) = 1$

$D'_2(X = 0) \Rightarrow Ent(D'_2) = -(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{2}\log_2 \frac{1}{2}) = 1$

因此 $Gain(D'_0, X) = Ent(D'_0) - \sum_{v=1}^2 \frac{|D^v|}{|D|} Ent(D^v) = 1 - (\frac{1}{2} \times 1 + \frac{1}{2} \times 1) = 0$


$D'_3(Y=1) \Rightarrow Ent(D'_3) = -(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2}) = 1$

$D'_4(Y=0) \Rightarrow Ent(D'_4) = -(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2}) = 1$

因此 $Gain(D'_0, Y) = Ent(D'_0) - \sum_{v=1}^2 \frac{|D^v|}{|D|} Ent(D^v) = 1 - (\frac{1}{2} \times 1 + \frac{1}{2} \times 1) = 0$

由于 $Gain(D'_0, X) = Gain(D'_0, Y)$ ，因此按照字母顺序，第二个分支结点选择 X 。由于 X 确定后，仍不能确定 f 的值，故仍需要第三个分支结点 Y

构建出的决策树如下：



(b)

1. D 中只包含一个类别

因为只有一个类别，因此 $|y| = 1, p_1 = 1$

信息熵： $Ent(D) = -\sum_{i=1}^{|y|} p_i \log_2 p_i = -(1 \log_2 1) = 0$

基尼指数： $Gini(D) = 1 - \sum_{k=1}^{|y|} p_k^2 = 1 - 1^2 = 0$

2. D 中所有类别的样本量相等，即 $p_k = \frac{1}{|y|}$

信息熵： $Ent(D) = -\sum_{i=1}^{|y|} p_i \log_2 p_i = -\sum_{i=1}^{|y|} \frac{1}{|y|} \log_2 \frac{1}{|y|} = -\log_2 \frac{1}{|y|}$

基尼指数： $Gini(D) = 1 - \sum_{k=1}^{|y|} p_k^2 = 1 - \sum_{k=1}^{|y|} \left(\frac{1}{|y|}\right)^2 = 1 - |y| \left(\frac{1}{|y|}\right)^2 = 1 - \frac{1}{|y|}$

题目2

(a)

$$g(w, b) = \frac{1}{2} \|Xw + 1b^T - y\|_2^2 + \lambda \|w\|_2^2 = \frac{1}{2} (Xw + 1b^T - y)^T (Xw + 1b^T - y) + \lambda w^T w \quad (1)$$

有：

$$\begin{aligned} \frac{\partial g}{\partial w} &= \frac{1}{2} \frac{\partial((Xw + 1b^T - y)^T (Xw + 1b^T - y))}{\partial w} + \lambda \frac{\partial w^T w}{\partial w} \\ &= \frac{1}{2} \frac{\partial(w^T X^T Xw + w^T X^T (1b)^T - w^T X^T y + (1b)Xw - y^T Xw)}{\partial w} + 2\lambda w \\ &= \frac{1}{2} ((X^T X + X^T X)w + X^T (1b)^T - X^T y + (1b)X - y^T X) + 2\lambda w \\ &= (X^T X + 2\lambda I)w + (1b)X - y^T X \end{aligned}$$

以及：

$$\begin{aligned} \frac{\partial g}{\partial b} &= \frac{1}{2} \frac{\partial((Xw + (1b)^T - y)^T (Xw + (1b)^T - y))}{\partial b} + \lambda \frac{\partial w^T w}{\partial b} \\ &= \frac{1}{2} \frac{\partial((1b)Xw - (1b)y + w^T X^T (1b)^T + (1b)(1b)^T - y^T (1b)^T)}{\partial b} + 0 \\ &= \frac{1}{2} \frac{\partial(2(1b)Xw - 2(1b)y + (1b)(1b)^T)}{\partial b} \\ &= 1Xw - 1y + b \end{aligned}$$

因此令 $\frac{\partial g}{\partial w} = \frac{\partial g}{\partial b} = 0$, 有

$$w = \frac{(y^T - 1b)X}{(X^T X + 2\lambda I)}, \quad b = \frac{1(y - Xw)}{n} \quad (2)$$

其中 n 为样本数。

而对于原始线性回归的最优解为

$$w = \frac{(y^T - b)X}{X^T X}, \quad b = \bar{y} - \bar{x}^T w = \frac{1(y - Xw)}{n} \quad (3)$$

因此 $b_{Ridge}^* = b_{LS}^*$, 而 w_{Ridge}^* 和 w_{LS}^* 的区别在于前者的分母多了一个 $2\lambda I$ 的偏移。

(b)

因为 $XX^T = \|X\|_2^2 \succeq 0$, 故若 $\lambda > 0$, 有 $(XX^T + \lambda I_m) \succ 0, (X^T X + \lambda I_d) \succ 0$.

两侧同时左乘 $(XX^T + \lambda I_m)$, 左侧：

$$(XX^T + \lambda I_m)(XX^T + \lambda I_m)^{-1}X = X$$

右侧：

$$\begin{aligned} (XX^T + \lambda I_m)X(X^T X + \lambda I_d)^{-1} &= (XX^T X + \lambda I_m X)(X^T X + \lambda I_d)^{-1} \\ &= XX^T X(X^T X + \lambda I_d)^{-1} + \lambda X(X^T X + \lambda I_d)^{-1} \\ &= X(X^T X)(X^T X + \lambda I_d)^{-1} + \lambda X(X^T X + \lambda I_d)^{-1} \\ &= X(X^T X + \lambda I_d)(X^T X + \lambda I_d)^{-1} \\ &= X \end{aligned}$$

因此左侧等于右侧，即

$$(XX^T + \lambda I_m)^{-1}X = X(X^T X + \lambda I_d)^{-1} \quad (4)$$

通过此结论，我们可以得到

$$w = \frac{(y^T - 1b)X}{(X^T X + 2\lambda I)} = \frac{(y^T - 1b)}{(XX^T + 2\lambda I)}X \quad (5)$$

这个结论主要实现了一个矩阵维度的变换，假设 X 是一个 $m \times n$ 的矩阵，前者的括号中是 $n \times n$ 的矩阵，后者的括号中是 $m \times m$ 矩阵。在实际计算中，如果 m 和 n 存在显著的大小差异，我们选择计算出尺寸较小的那个矩阵，有利于加快矩阵的运算，并且减小计算过程中存储矩阵的空间。

题目3

由已知有：

$$\begin{aligned} \ln \frac{P(y = i|x)}{P(y = N|x)} &= w_i^T x + b_i \Rightarrow \frac{P(y = i|x)}{P(y = N|x)} = \exp(w_i^T x + b_i) \\ &\Rightarrow P(y = i|x) = \exp(w_i^T x + b_i) P(y = N|x) \end{aligned}$$

因为

$$\sum_{i=1}^{n-1} P(y = i|x) = 1 - P(y = N|x) \quad (6)$$

故

$$\begin{aligned} 1 - P(y = N|x) &= \sum_{i=1}^{n-1} P(y = i|x) \\ &= \sum_{i=1}^{n-1} \exp(w_i^T x + b_i) P(y = N|x) \\ &= P(y = N|x) \sum_{i=1}^{n-1} \exp(w_i^T x + b_i) \end{aligned}$$

有

$$\begin{aligned} P(y = N|x) &= \frac{1}{1 + \sum_{i=1}^{n-1} \exp(w_i^T x + b_i)} \\ P(y = i|x) &= \frac{\exp(w_i^T x + b_i)}{1 + \sum_{i=1}^{n-1} \exp(w_i^T x + b_i)} \end{aligned} \quad (7)$$

因此优化目标为

$$\min_{w_j, b_j} - \sum_{i=1}^m \sum_{j=1}^{n-1} \mathbb{I}_j(y_i) \ln P(y_j|x)$$

其中 $\mathbb{I}_j$ 为指示函数， $\mathbb{I}_j(y_i) = 1$ 当且仅当 $y_i = j$ ，否则为0。令 $\beta_j x = w_j^T x + b_j$ ，有

$$\min_{\beta_j} - \sum_{i=1}^m \sum_{j=1}^{n-1} \mathbb{I}_j(y_i) \ln \frac{\exp(\beta_j x)}{1 + \sum_{k=1}^{n-1} \exp(\beta_k x)} \quad (8)$$

题目4

(a)

$$y(w^T x + b) > 0 \quad (9)$$

对于一个正类的样本，即 $y_i = 1$ ，若判断正确则应该 $w^T x + b > 0$ ，故有 $y_i(w^T x_i + b) > 0$ 。

对于一个负类的样本，即 $y_i = -1$ ，若判断正确则应该 $w^T x_i + b < 0$ ，故有 $y_i(w^T x_i + b) > 0$ 。

(b)

记样本为 x_0 ，过 x_0 做一条垂直于超平面的垂线：

$$l : x = x_0 + tw \quad (10)$$

将垂线与平面方程进行联立，计算出交点：

$$\begin{cases} l : x = x_0 + tw \\ w^T x + b = 0 \end{cases} \Rightarrow w^T (x_0 + tw) + b = 0 \quad (11)$$

故解得 $t = -\frac{w^T x_0 + b}{\|w\|_2^2}$ ，交点 $x_1 = x_0 - \frac{w^T x_0 + b}{\|w\|_2^2} w$ 。

因此 x_0 到平面的距离即 x_0 到 x_1 的距离，故：

$$\begin{aligned} \rho_h(x) &= \|x_0 - x_1\|_2 \\ &= \left\| \frac{w^T x_0 + b}{\|w\|_2^2} w \right\| \\ &= \frac{|w^T x_0 + b|}{\|w\|} \end{aligned}$$

(c)

$$\begin{aligned} \max_{w,b} \min_{i \in [m]} \rho_h(x_i) &= \frac{|w^T x_i + b|}{\|w\|}, \quad [m] = \{1, 2, \dots, m\} \\ \text{s.t.} \quad y_i(w^T x_i + b) &> 0, \quad i = 1, 2, \dots, m \end{aligned}$$

(d)

假设 w_0, b_0 是该优化问题的一组解，考虑 kw_0, kb_0 ，其中 $k > 0$ 。

因为 $y_i(w_0^T x_i + b_0) > 0$ ，因此 $y_i(kw_0^T x_i + kb_0) = ky_i(w_0^T x_i + b_0) > 0$ 。

同时

$$\frac{|kw_0^T x_i + kb_0|}{\|kw_0\|} = \frac{k|w_0^T x_i + b_0|}{k\|w_0\|} = \frac{|w_0^T x_i + b_0|}{\|w_0\|} \quad (12)$$

因此 kw_0 和 kb_0 显然与 w_0 和 b_0 等效，也是最优解。而 k 的取值是无穷的，因此该问题有无穷多组最优解。

(e)

由于 $\min_{i \in [m]} |w^T x_i + b| = 1$ 以及 $\min_{i \in [m]} y_i(w^T x_i + b) = 1$ 。因此 $\mathcal{P}^1$ 转换为：

$$\begin{aligned} \max_{w,b} \quad & \frac{1}{\|w\|} \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, m \end{aligned}$$

将最大化问题转换为最小化问题，只需要对目标函数取倒数即可

$$\begin{aligned} \max_{w,b} \quad & \|w\| \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, m \end{aligned}$$