

《人工智能导论》2025

智能科学与技术学院

第二次作业-监督学习

1. 决策树(Decision Tree)

(a) (15pt) 假设有一个包含 3 个布尔属性 X, Y, Z 的属性空间，目标函数 $f = f(X, Y, Z)$ 作为标记空间，它们形成的数据集见下表。请使用信息增益作为划分标准画出决策树的生成过程。当两个属性的信息增益相同时，依据字母顺序选择属性。

编号	X	Y	Z	f	编号	X	Y	Z	f
1	1	0	1	1	5	0	1	0	0
2	1	1	0	0	6	0	0	1	0
3	0	0	0	0	7	1	0	0	0
4	0	1	1	1	8	1	1	1	0

(b) (10pt) 假设决策树分类问题中标记空间 $\mathcal{Y}$ 的大小为 $|\mathcal{Y}|$ ，训练集 D 中第 k 类样本所占比例为 p_k ，考虑两种极端情况：(i) D 中只包含一个类别，(ii) D 中所有类别的样本量相等 (i.e. $p_k = \frac{1}{|\mathcal{Y}|}$)，计算信息熵和基尼指数的取值。

2. 线性回归(Linear Regression)

在实际问题中，常常会遇到样本相对较少而特征很多的场景，在这类情况中如果直接求解线性回归模型，无法根据较少的样本获得唯一的模型参数，会有多个模型能够“完美”拟合训练集中的所有样本。此外，模型很容易出现过拟合。为缓解这些问题，根据

结构风险最小化的原则,可以引入正则化项 $\Omega(\mathbf{w})$, 通常形式如下:

$$\mathbf{w}_{\text{Ridge}}^*, b_{\text{Ridge}}^* = \underset{\mathbf{w}, b}{\operatorname{argmin}} \frac{1}{2} \|\mathbf{X}\mathbf{w} + \mathbf{1}_m b - \mathbf{y}\|_2^2 + \lambda \Omega(\mathbf{w})$$

其中, $\lambda > 0$ 为正则化参数。正则化表示了对模型的一种偏好, 例如 $\Omega(\mathbf{w})$ 一般对模型的复杂度进行约束, 因此相当于从多个在训练集上具有相同预测结果的模型中选出模型复杂度最低的一个。

考虑岭回归问题, 即设置正则项 $\Omega(\mathbf{w}) = \|\mathbf{w}\|_2^2$ 。本题中将对岭回归的闭式解以及正则化的影响进行探讨。请回答以下问题:

(a) (15pt) 请给出岭回归的最优解 $\mathbf{w}_{\text{Ridge}}^*$ 和 b_{Ridge}^* 的闭式解表达式,

使用矩阵形式表示, 并分析其最优解和原始线性回归最优解

$\mathbf{w}_{\text{LS}}^*$ 和 b_{LS}^* 的区别。注: 在本题中我们不采用课上讲的技巧,

将 b 写入 $\mathbf{W}$ 中, 而是分开表达, 即定义岭回归的目标函数为:

$$g(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{X}\mathbf{w} + \mathbf{1}b^\top - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_2^2$$

(b) (10pt) 请证明对于任何矩阵 $\mathbf{X} \in \mathbb{R}^{m \times d}$, 下式均成立:

$$(\mathbf{X}\mathbf{X}^\top + \lambda \mathbf{I}_m)^{-1} \mathbf{X} = \mathbf{X}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}_d)^{-1}$$

上述结论是否有助于岭回归的计算, 在何种情况下能够带来帮助?

3. 对数几率回归(Logistic Regression):

(25pt) 在本题目中, 我们考虑将对数几率回归扩展至多分类问题, 在多分类问题中进行预测时, 如已知给定 $\mathbf{x}$ 时, 前 $N-1$ 个类别的后验概率, 则可直接得到第 N 个类别的后验概率。因此, 分别将前 $N-1$ 个类别的后验概率和第 N 个类别的后验概率进行比较, 构建

$N - 1$ 组对数几率, 分别用 $N - 1$ 组线性模型进行预测:

$$\begin{aligned}\ln \frac{P(y = 1 | \mathbf{x})}{P(y = N | \mathbf{x})} &= \mathbf{w}_1^\top \mathbf{x} + b_1, \\ \ln \frac{P(y = 2 | \mathbf{x})}{P(y = N | \mathbf{x})} &= \mathbf{w}_2^\top \mathbf{x} + b_2, \\ &\vdots \\ \ln \frac{P(y = N - 1 | \mathbf{x})}{P(y = N | \mathbf{x})} &= \mathbf{w}_{N-1}^\top \mathbf{x} + b_{N-1}.\end{aligned}$$

请通过极大似然估计的方法构建目标函数, 给出该多分类对率回归模型的优化目标 (以最小化的形式), 为了简化符号, 你可以将偏移项 b 合并到分类器权重中, 比如令 $\boldsymbol{\beta}_n = (\mathbf{w}_n, b_n)$ 。

4. 支持向量机(Support Vector Machine)

考虑 d 维空间中的二分类问题, 输入空间为 $\mathcal{X} \in \mathbb{R}^d$, 输出空间为 $\mathcal{Y} = \{-1, +1\}$ 。从数据分布 $\mathcal{D}$ 中采样得到一个包含 m 个样本的线性可分数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ 。令 $h: \mathcal{X} \rightarrow \mathcal{Y}$ 表示某个线性分类器, 即 $h \in \mathcal{H} = \{x \rightarrow \text{sign}(\mathbf{w}^\top \mathbf{x} + b): \mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}\}$ 。试回答:

- (a) (5pt) 对于一个样本 (x, y) , 请用包含 $x, y, \mathbf{w}, b$ 的不等式表达“该样本被分类正确”
- (b) (5pt) 基于线性分类器 h 的等式 $\mathbf{w}^\top \mathbf{x} + b = 0$ 确定了 d 维空间中的一个超平面。令 $\rho_h(x)$ 表示样本 x 到由 h 确定的超平面的欧式距离, 试求 $\rho_h(x)$ 。
- (c) (5pt) 定义分类器 h 的间隔为数据集中所有样本到分类器超平面的最短距离 $\rho = \min_{i \in [m]} \rho_h(x_i)$ 。其中, $[m] = \{1, 2, \dots, m\}$ 。如果我们希望寻找“能将所有样本分类正确且间隔最大”的分类器。试写出

该优化问题，我们将该问题称为问题 $\mathcal{P}^1$ 。

(d) (5pt) $\mathcal{P}^1$ 是一个关于参数 w, b 的优化问题。然而，该问题有无穷多组最优解。请证明该结论。

(e) (5pt) 虽然 $\mathcal{P}^1$ 有无穷多组最优解，但这些最优解将给出等价的分类器。所以对 $\mathcal{P}^1$ 做一些限制，如通过参数尺度的缩放要求样本到超平面的最短距离为 1，即 $\min_{i \in [m]} |w^T x_i + b| = 1$ (或者等价地， $\min_{i \in [m]} y_i (w^T x_i + b) = 1$)，请写出该条件下 $\mathcal{P}^1$ 转化后的优化问题 $\mathcal{P}^2$ ，并尝试把最大化问题转换为最小化问题，写出问题 $\mathcal{P}^3$ 。

附加题(0pt): 支持向量机(Support Vector Machine)

泛化误差表达了分类器在数据分布上的平均错误率，对于分类器 h ，其在数据分布 $\mathcal{D}$ 上的泛化误差定义如下：

$$R(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\mathbb{I}(h(x) \neq y)],$$

即对于分布 $\mathcal{D}$ 中所抽取样本 (x, y) 被误分类个数的期望。

留一损失使用留一法对分类器泛化误差进行估计：基于数据集 D 每次使用一个样本 $\{x_i\}$ 作为测试集，将剩余样本 $D - \{x_i\}$ 作为训练集，最后对所有测试误差求平均。

对于 SVM，令 h_D 为该算法在训练集 D 上的输出，则该算法的经验留一损失可形式化定义为：

$$\hat{R}_{\text{LoO}} = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(h_{D-\{x_i\}}(x_i) \neq y_i)$$

本题针对可分情形，通过探索留一损失的数学性质，分析 SVM 的

泛化误差。

(a) 在实践中, 可通过给定数据集 D 上的留一损失近似泛化误差, 试证明留一损失满足以下性质:

$$\mathbb{E}_{D \sim \mathcal{D}^m}[\hat{R}_{\text{LOO}}] = \mathbb{E}_{D' \sim \mathcal{D}^{m-1}}[R(h_{D'})],$$

其中 $\mathcal{D}^m$ 表示从数据分布 $\mathcal{D}$ 中独立采样的 m 个样本组成的元组 $(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m)$ 所服从的分布。换句话说, $D \sim \mathcal{D}^m$ 表示 D 是一个大小为 m 的数据集, 其中每个样本都独立且服从分布 $\mathcal{D}$ 。

(b) SVM 的训练结果仅与支持向量有关。这一现象可以抽象地表示为, 如果 $\mathbf{x}$ 不是 h_D 的支持向量, 则 $h_{D-\{\mathbf{x}\}} = h_D$ 。该性质在分析误差时有关键作用, 考虑如下问题: 如果 $\mathbf{x}$ 不是 h_D 的支持向量, $h_{D-\{\mathbf{x}\}}$ 会将 $\mathbf{x}$ 正确分类吗? 为什么? 该问题结论的逆否命题是什么?

(c) 基于上一小题的结果, 试证明下述 SVM 的泛化误差界:

$$\mathbb{E}_{D \sim \mathcal{D}^m}[R(h_D)] \leq \mathbb{E}_{D \sim \mathcal{D}^{m+1}} \left[\frac{N_{\text{DV}}(D)}{m+1} \right]$$

其中 $N_{\text{DV}}(D)$ 为 h_D 支持向量的个数。