

第三次作业

题目一

(1)

由题目可知：

$$\begin{aligned}\hat{y}_1 &= \text{Sigmoid}(\beta_1 - \theta_1) \\ &= \frac{1}{1 + e^{-(\beta_1 - \theta_1)}}\end{aligned}$$

因此可得：

$$\begin{aligned}\frac{\partial \hat{y}_1}{\partial \beta_1} &= -1 \times \frac{1}{(1 + e^{-(\beta_1 - \theta_1)})^2} e^{-(\beta_1 - \theta_1)} \times -1 \\ &= \frac{e^{-(\beta_1 - \theta_1)}}{(1 + e^{-(\beta_1 - \theta_1)})^2} \\ &= (1 - \hat{y}_1)\hat{y}_1\end{aligned}$$

对于 $\ell(y, \hat{y}_1) = -[y \log(\hat{y}_1) + (1 - y) \log(1 - \hat{y}_1)]$ ，有：

$$\begin{aligned}\frac{\partial \ell(y, \hat{y}_1)}{\partial \hat{y}_1} &= -\frac{y}{\hat{y}_1} + \frac{(1 - y)}{1 - \hat{y}_1} \\ &= \frac{(\hat{y}_1 - 1)y + (1 - y)\hat{y}_1}{\hat{y}_1(1 - \hat{y}_1)} \\ &= \frac{\hat{y}_1 - y}{\hat{y}_1(1 - \hat{y}_1)}\end{aligned}$$

因此，

$$\begin{aligned}\frac{\partial \ell(y, \hat{y}_1)}{\partial \beta_1} &= \frac{\partial \ell(y, \hat{y}_1)}{\partial \hat{y}_1} \frac{\partial \hat{y}_1}{\partial \beta_1} \\ &= \frac{\hat{y}_1 - y}{\hat{y}_1(1 - \hat{y}_1)} (1 - \hat{y}_1)\hat{y}_1 \\ &= \hat{y}_1 - y\end{aligned}$$

(2)

对于 $\ell(y, \hat{y}) = -\sum_{j=1}^l y_j \log \hat{y}_j$ ，有：

$$\frac{\partial \ell(y, \hat{y})}{\partial \hat{y}} = \left(-\frac{y_1}{\hat{y}_1}, -\frac{y_2}{\hat{y}_2}, \dots, -\frac{y_l}{\hat{y}_l}\right)^T$$

且有题目可知，

$$\begin{aligned}\hat{y} &= (\hat{y}_1, \hat{y}_2, \dots, \hat{y}_l)^T \\ &= \left(\frac{e^{\beta_1}}{\sum_{k=1}^l e^{\beta_k}}, \frac{e^{\beta_2}}{\sum_{k=1}^l e^{\beta_k}}, \dots, \frac{e^{\beta_l}}{\sum_{k=1}^l e^{\beta_k}}\right)\end{aligned}$$

因此对于单独的 $\hat{y}_j$ 可得：

- 若 $j = i$

$$\begin{aligned}
\frac{\partial \hat{y}_j}{\partial \beta_i} &= \frac{e^{\beta_j}}{\sum_{k=1}^l e^{\beta_k}} - \frac{e^{\beta_j}}{(\sum_{k=1}^l e^{\beta_k})^2} e^{\beta_i} \\
&= \frac{e^{\beta_j}}{\sum_{k=1}^l e^{\beta_k}} \left(1 - \frac{e^{\beta_j}}{\sum_{k=1}^l e^{\beta_k}} \right) \\
&= \hat{y}_j (1 - \hat{y}_j)
\end{aligned}$$

- 若 $j \neq i$

$$\begin{aligned}
\frac{\partial \hat{y}_j}{\partial \beta_i} &= -\frac{e^{\beta_j}}{(\sum_{k=1}^l e^{\beta_k})^2} e^{\beta_i} \\
&= -\frac{e^{\beta_j}}{\sum_{k=1}^l e^{\beta_k}} \frac{e^{\beta_i}}{\sum_{k=1}^l e^{\beta_k}} \\
&= -\hat{y}_j \hat{y}_i
\end{aligned}$$

因此

$$\begin{aligned}
\frac{\partial \ell}{\partial \beta_k} &= \sum_{j=1}^l \frac{\partial \ell}{\partial \hat{y}_j} \frac{\partial \hat{y}_j}{\partial \beta_k} \\
&= -\sum_{j=1}^l \frac{y_j}{\hat{y}_j} \frac{\partial \hat{y}_j}{\partial \beta_k} \\
&= -\sum_{j=1}^l \begin{cases} y_j(1 - \hat{y}_j), & j = k \\ -y_j \hat{y}_k, & j \neq k \end{cases}
\end{aligned}$$

由于对于第 i 类样本有, $y_i = 1, y_j = 0, i \neq j$.

- 当 $k = i$ 时,

$$\frac{\partial \ell}{\partial \beta_k} = -y_i(1 - \hat{y}_i) = \hat{y}_i - 1 = \hat{y}_i - y_i \quad (1)$$

- 当 $k \neq i$ 时,

$$\frac{\partial \ell}{\partial \beta_k} = -y_i \hat{y}_k = -\hat{y}_k = \hat{y}_k - y_k \quad (2)$$

因此

$$\frac{\partial \ell}{\partial \beta} = (\hat{y}_1 - y_1, \hat{y}_2 - y_2, \dots, \hat{y}_l - y_l)^T \quad (3)$$

(3)

在二分类问题中, 通过问题(1)、(2)的计算可以发现二者的损失函数关于 β 的计算结果是一致的。

不同在于 *sigmoid* 激活函数在二分类问题中只会有一个输出, 而 *softmax* 激活函数在二分类问题中会有两个输出。

但是考虑 *softmax* 激活函数在二分类下的公式:

$$\begin{aligned}
y_1 &= \frac{e^{\beta_1}}{e^{\beta_1} + e^{\beta_2}} \\
&= \frac{1}{1 + e^{\beta_2 - \beta_1}} \\
&= \frac{1}{1 + e^{-(\beta_1 - \beta_2)}}
\end{aligned}$$

令 $\beta = \beta_1 - \beta_2$, 则 *softmax* 激活函数也能转化为

$$y_1 = \frac{1}{1 + e^{-\beta}} \quad (4)$$

与sigmoid激活函数的形式一致，因此在二分类问题中，softmax本质上就是退化为了一个sigmoid函数

(4)

对于KL散度公式，可转换为

$$\begin{aligned} D_{KL}(P||Q) &= \sum_{x \in \mathcal{X}} P(x) \log \left(\frac{P(x)}{Q(x)} \right) \\ &= \sum_{x \in \mathcal{X}} P(x) \log(P(x)) - \sum_{x \in \mathcal{X}} P(x) \log(Q(x)) \\ &= - \sum_{x \in \mathcal{X}} P(x) \log \frac{1}{P(x)} + \sum_{x \in \mathcal{X}} P(x) \log \frac{1}{Q(x)} \end{aligned}$$

$$\text{因为 } \ell(y, \hat{y}) = \sum_{j=1}^l y_j \log \frac{1}{\hat{y}_j}, \quad \ell(y, y) = \sum_{j=1}^l y_j \log \frac{1}{y_j}$$

因此令 $y_j = P(x), \hat{y}_j = Q(x)$, 有

$$D_{KL}(P||Q) = \ell(y, \hat{y}) - \ell(y, y) \quad (5)$$

题目二

(1)

对于第*i*层而言 $i = 0, 1$:

输入 X_i , 前向传递: $X_{i+1} = \sigma(X_i W_i + 1_m b_i)$.

因此

$$X_3 = \sigma(\sigma(X_0 W_0 + 1_m b_0) W_1 + 1_m b_1) W_2 + 1_m b_2 \quad (6)$$

最后计算损失:

$$\ell = \frac{1}{2ml} \|X_3 - Y\|_F^2 \quad (7)$$

(2)

对于 ℓ , 可进行进一步转换:

$$\begin{aligned} \ell &= \frac{1}{2ml} \|X_3 - Y\|_F^2 \\ &= \frac{1}{2ml} \sum_{ij} (X_{3,ij} - Y_{ij})^2 \end{aligned}$$

反向传播:

$$\begin{aligned} \frac{\partial \ell}{\partial X_{3,ij}} &= \frac{1}{2ml} 2(X_{3,ij} - Y_{ij}) \\ &= \frac{1}{ml} (X_{3,ij} - Y_{ij}) \end{aligned}$$

转换为矩阵形式:

$$\begin{aligned}\frac{\partial \ell}{\partial X_3} &= \frac{1}{2ml} 2(X_3 - Y_{ij}) \\ &= \frac{1}{ml} (X_3 - Y_{ij})\end{aligned}$$

由题目一可知，若 $Y = \sigma(x)$ ，则 $Y' = Y \odot (1 - Y)$ 。

不妨设 $Z_0 = X_0 W_0 + b_0$, $Z_1 = X_1 W_1 + b_1$ ，因此进一步可得：

$$\begin{aligned}\frac{\partial X_3}{\partial W_2} &= X_2^T, & \frac{\partial X_3}{\partial b_2} &= 1_m^T, & \frac{\partial X_3}{\partial X_2} &= W_2^T, & \frac{\partial X_2}{\partial Z_1} &= X_2 \odot (1 - X_2), \\ \frac{\partial Z_1}{\partial W_1} &= X_1^T, & \frac{\partial Z_1}{\partial b_1} &= 1_m^T, & \frac{\partial Z_1}{\partial X_1} &= W_1^T, & \frac{\partial X_1}{\partial Z_0} &= X_1 \odot (1 - X_1) \\ \frac{\partial Z_0}{\partial W_0} &= X_0^T, & \frac{\partial Z_0}{\partial b_0} &= 1_m^T\end{aligned}$$

因此，可计算出：

$$\frac{\partial \ell}{\partial W_2} = \frac{\partial \ell}{\partial X_3} \frac{\partial X_3}{\partial W_2} = \frac{1}{ml} X_2^T (X_3 - Y), \quad \frac{\partial \ell}{\partial b_2} = \frac{\partial \ell}{\partial X_3} \frac{\partial X_3}{\partial b_2} = \frac{1}{ml} 1_m^T (X_3 - Y) \quad (8)$$

$$\frac{\partial \ell}{\partial Z_1} = \frac{\partial \ell}{\partial X_3} \frac{\partial X_3}{\partial X_2} \odot \frac{\partial X_2}{\partial Z_1} = \frac{1}{ml} (X_3 - Y) W_2^T \odot X_2 \odot (1 - X_2) \quad (9)$$

$$\begin{aligned}\frac{\partial \ell}{\partial W_1} &= \frac{\partial \ell}{\partial Z_1} \frac{\partial Z_1}{\partial W_1} = \frac{1}{ml} X_1^T (X_3 - Y) W_2^T \odot X_2 \odot (1 - X_2) \\ \frac{\partial \ell}{\partial b_1} &= \frac{\partial \ell}{\partial Z_1} \frac{\partial Z_1}{\partial b_1} = \frac{1}{ml} 1_m^T (X_3 - Y) W_2^T \odot X_2 \odot (1 - X_2)\end{aligned} \quad (10)$$

$$\frac{\partial \ell}{\partial Z_0} = \frac{\partial \ell}{\partial Z_1} \frac{\partial Z_1}{\partial X_1} \odot \frac{\partial X_1}{\partial Z_0} = \frac{1}{ml} [(X_3 - Y) W_2^T \odot X_2 \odot (1 - X_2)] W_1^T \odot [X_1 \odot (1 - X_1)] \quad (11)$$

$$\begin{aligned}\frac{\partial \ell}{\partial W_0} &= \frac{\partial \ell}{\partial Z_0} \frac{\partial Z_0}{\partial W_0} = \frac{1}{ml} X_0^T [(X_3 - Y) W_2^T \odot X_2 \odot (1 - X_2)] W_1^T \odot [X_1 \odot (1 - X_1)] \\ \frac{\partial \ell}{\partial b_0} &= \frac{\partial \ell}{\partial Z_0} \frac{\partial Z_0}{\partial b_0} = \frac{1}{ml} 1_m^T [(X_3 - Y) W_2^T \odot X_2 \odot (1 - X_2)] W_1^T \odot [X_1 \odot (1 - X_1)]\end{aligned} \quad (12)$$

题目三

(1)

假设第 i 层第 j 个节点的输入为 X_{ij} ，第 i 层第 j 个节点的输出为 Z_{ij} ，则有

$$Z_{ij} = \sum_j W_{ij} X_{ij} + b_i \quad (13)$$

如果是全零初始化，则在第一次传播中，当 $i \geq 1$ 时有 $Z_i = b_i$, $X_i = b_{i-1}$ 。注意到对于任意的 j , $Z_{ij} = Z_i = b_i$ 。即同一层输入值以及输出值都是一致的。在反向传播中， $\frac{\partial \ell}{\partial W_i}$ 跟 $Z_i, Z_{i+1}, \dots, Z_n$ 相关，但是由于同一层的输出都是相同的，进而使得同一层的 $\frac{\partial \ell}{\partial W}$ 都是相同的，即同一层的反向传播结果相同。从而又有同一层的权重参数变化也相同，导致的结果便是无论过多少个 *epoch*，同一层的参数永远是相同的。

(2)

对于一个二层的MLP网络，我们假设有 k 个输入 x_i ，隐藏层有 l 个节点 h_i ，最后有 m 个输入 y_i 。

对于所有权重，我们用 *Xavier* 的方法进行初始化，即 $W \sim \mathcal{N}(0, \frac{2}{n_{in} + n_{out}})$ 。

下面我们考虑前向传播的过程，从输入层到隐藏层有：

$$h_j = \sum_{i=1}^k w_{ij} x_i \quad (14)$$

一开始的 w_{ij} 服从 $\mathcal{N}(0, \frac{2}{n_{in}+n_{out}})$ ，倘若我们忽略点乘 x_i 对分布造成的影响，只考虑求和。则对 $w_{ij}x_i$ 求和后，有 $h_j \sim \mathcal{N}(0, \frac{2k}{n_{in}+n_{out}})$ ，而可以注意到这里的 k 即 n_{in} 。进一步考虑从隐藏层到输出层有：

$$y_j = \sum_{i=1}^l w_{ij} h_i \quad (15)$$

同理可得，若与 h_i 点乘不影响最终的分布，则可得到 $y_j \sim \mathcal{N}(0, \frac{2l}{n_{in}+n_{out}})$ ，可以注意到此时这里的 l 即 n_{in} 。

下面考虑反向传播的过程，从损失函数到隐藏层输出 z 有：

$$\frac{\partial \ell}{\partial z} = \frac{\partial \ell}{\partial y} \frac{\partial y}{\partial z} \cdot \sigma'(z) = W_2 \frac{\partial \ell}{\partial y} \cdot \sigma'(z) \quad (16)$$

假设 $\sigma'(z)$ 不影响结果的方差，考虑 $W_2 \frac{\partial \ell}{\partial y}$ ，其中第 i 个分量为

$$\sum_{j=1}^m w_{ij} \frac{\partial \ell}{\partial y_j} \quad (17)$$

因此考虑求和对方差造成的影响有： $\left[W_2 \frac{\partial \ell}{\partial y} \right]_i \sim \mathcal{N}(0, \frac{2m}{n_{in}+n_{out}})$ ，此时注意到这里的 m 即 n_{out} 。进一步考虑从损失函数到输入层有：

$$\left[W_1 \frac{\partial \ell}{\partial x} \right]_i = \sum_{j=1}^l w_{ij} \frac{\partial \ell}{\partial z_j} \quad (18)$$

同理有： $\left[W_1 \frac{\partial \ell}{\partial x} \right]_i \sim \mathcal{N}(0, \frac{2l}{n_{in}+n_{out}})$ ，此时注意到这里的 l 即 n_{out} 。

因此可以看出之所以Xavier要设置成 $\mathcal{N}(0, \frac{2}{n_{in}+n_{out}})$ ，主要是为了在前向传播和反向传播的过程中尽可能实现方差稳定，使参数保持在适当的范围内，防止梯度爆炸或梯度消失。

那么对于考虑ReLU，它会将小于0的数字全部化为0，这一操作会对参数的方差存在较强的影响，使得Xavier初始化失去稳定参数方差的效果，故显然是不合适的。而对于 $\tanh(x)$ 和 $\text{sigmoid}(x)$ 激活函数，它们在 $x = 0$ 的附近区间内近似于线性映射，对方差的影响作用较小，同时也不会和ReLU一样有较强的均值偏移。

题目四

(1)

第一步，输入乘以 KQV 矩阵

$$Q = W_Q X = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 & 0 & 2 \\ 0 & 1 & 0 & 0 \\ 0 & 2 & 1 & 0 \\ 0 & 0 & 1 & 1 \\ 2 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 & 0 & 2 \\ 0 & 1 & 1 & 1 \\ 3 & 2 & 2 & 1 \end{bmatrix} \quad (19)$$

$$K = W_K X = \begin{bmatrix} 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} 2 & 0 & 0 & 2 \\ 0 & 1 & 0 & 0 \\ 0 & 2 & 1 & 0 \\ 0 & 0 & 1 & 1 \\ 2 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 2 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & -1 & 1 \end{bmatrix} \quad (20)$$

$$V = W_V X = \begin{bmatrix} 10 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 10 & 0 & 0 \\ 0 & 10 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 2 & 0 & 0 & 2 \\ 0 & 1 & 0 & 0 \\ 0 & 2 & 1 & 0 \\ 0 & 0 & 1 & 1 \\ 2 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 20 & 0 & 0 & 20 \\ 0 & 0 & 10 & 10 \\ 0 & 10 & 0 & 0 \end{bmatrix} \quad (21)$$

第二步，计算 $K^T Q$

$$K^T Q = \begin{bmatrix} 0 & 0 & 1 \\ 2 & 1 & 0 \\ 1 & 0 & -1 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 & 0 & 2 \\ 0 & 1 & 1 & 1 \\ 3 & 2 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 2 & 2 & 1 \\ 4 & 3 & 1 & 5 \\ -1 & -1 & -2 & 1 \\ 3 & 2 & 2 & 1 \end{bmatrix} \quad (22)$$

第三步，Scale

$$\frac{K^T Q}{\sqrt{dk}} = \begin{bmatrix} \frac{3}{2} & 1 & 1 & \frac{1}{2} \\ 2 & \frac{3}{2} & \frac{1}{2} & \frac{5}{2} \\ -\frac{1}{2} & -\frac{1}{2} & -1 & \frac{1}{2} \\ \frac{3}{2} & 1 & 1 & \frac{1}{2} \end{bmatrix} \quad (23)$$

第四步，softmax

1. 先求 $\exp(\frac{K^T Q}{\sqrt{dk}})$

$$\exp(\frac{K^T Q}{\sqrt{dk}}) = \begin{bmatrix} 3^{\frac{3}{2}} & 3 & 3 & 3^{\frac{1}{2}} \\ 3^2 & 3^{\frac{3}{2}} & 3^{\frac{1}{2}} & 3^{\frac{5}{2}} \\ 3^{-\frac{1}{2}} & 3^{-\frac{1}{2}} & 3^{-1} & 3^{\frac{1}{2}} \\ 3^{\frac{3}{2}} & 3 & 3 & 3^{\frac{1}{2}} \end{bmatrix} \quad (24)$$

2. 按列求和得：

$$[19.97 \quad 11.77 \quad 8.07 \quad 20.78] \quad (25)$$

3. 每列进行归一化

$$\text{softmax}(\frac{K^T Q}{\sqrt{dk}}) \approx \begin{bmatrix} 0.2602 & 0.2548 & 0.3720 & 0.0833 \\ 0.4507 & 0.4413 & 0.2148 & 0.7500 \\ 0.0289 & 0.0490 & 0.0413 & 0.0833 \\ 0.2602 & 0.2548 & 0.3720 & 0.0833 \end{bmatrix} \quad (28)$$

第五步，MatMul

$$\begin{aligned}
Z &= V[\text{softmax}(\frac{K^T Q}{\sqrt{d_k}})]^T \\
&= \begin{bmatrix} 20 & 0 & 0 & 20 \\ 0 & 0 & 10 & 10 \\ 0 & 10 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0.2602 & 0.2548 & 0.3720 & 0.0833 \\ 0.4507 & 0.4413 & 0.2148 & 0.7500 \\ 0.0289 & 0.0490 & 0.0413 & 0.0833 \\ 0.2602 & 0.2548 & 0.3720 & 0.0833 \end{bmatrix} \\
&= \begin{bmatrix} 10.408 & 10.192 & 14.88 & 3.332 \\ 2.891 & 3.038 & 4.133 & 1.666 \\ 4.507 & 4.413 & 2.148 & 7.5 \end{bmatrix}
\end{aligned}$$

(2)

在 $transformer$ 的自注意力计算之中， K 和 Q 中的数值往往是从 $\mathcal{N}(0, 1)$ 分布中产生的随机变量。在计算 $K^T Q$ ，使用 K^T 中的每一行点乘 Q 中的每一列时，会有如下一个操作：

$$q \cdot k = \sum_{i=1}^{d_k} q_i k_i \quad (27)$$

假设 $q_i k_i$ 仍服从 $\mathcal{N}(0, 1)$ 分布，那么进行累加后 $q \cdot k \sim \mathcal{N}(0, d_k)$ 。

这意味着 $K^T Q$ 中的元素依从的分布的方差变大，更可能去得一些较大的数字。我们不妨设 $d_k = 64$ ，此时方差便以达到了4096。而在后续的计算中，我们紧接着要把逐元素作为 e 的指数进行运算，而对于 e^{50} ，这个数字便已经是10的21次方的数值。因此显然，我们应该控制数值的大小，使计算数值始终保持在适当的范围。因此可以让 $q \cdot k$ 继续服从 $\mathcal{N}(0, 1)$ 的分布，因此需要对 $K^T Q$ 除以 $\sqrt{d_k}$ 。